# Implémentation du PageRank avec MPI

Ayaz Badouraly

École Centrale Paris

13 avril 2016

### Plan

- Introduction
- 2 Algorithme du pagerank
- Implémentation
  - Les structures de données
  - Le programme
- 4 Bibliographie
- Conclusion

### Plan

- Introduction
- 2 Algorithme du pagerank
- 3 Implémentation
  - Les structures de données
  - Le programme
- 4 Bibliographie
- Conclusion

### Cadre historique: 1998, invention du pagerank



Sergey Brin



Lawrence PAGE

### Problématique

- En pratique : jeux de données énormes
- Solution : librairie MPI

### Problématique

• En pratique : jeux de données énormes

Solution : librairie MPI

## Plan

- Introduction
- Algorithme du pagerank
- 3 Implémentation
  - Les structures de données
  - Le programme
- 4 Bibliographie
- Conclusion

### Modélisation de la navigation du surfeur

- A : le surfeur clique sur un lien externe de sa page courante
- D : le surfeur arrive sur une page sans lien externe
- E : le surfeur change de page au hasard

### Modélisation de la navigation du surfeur

- A : le surfeur clique sur un lien externe de sa page courante
- D : le surfeur arrive sur une page sans lien externe
- E : le surfeur change de page au hasard

### Modélisation de la navigation du surfeur

- A : le surfeur clique sur un lien externe de sa page courante
- D : le surfeur arrive sur une page sans lien externe
- E : le surfeur change de page au hasard

#### Modélisation du web

$$M = dA + dD + (1 - d)E$$

où d est le damping factor

### Définition du pagerank

$$Mp = p$$

### Algorithme du pagerank

$$\begin{cases}
 p^0 = \begin{pmatrix} \frac{1}{\dim(M)} \\ \vdots \\ \frac{1}{\dim(M)} \end{pmatrix} \\
\forall n \in \mathbb{N} : p^{n+1} = Mp^n
\end{cases}$$

# Plan

- Introduction
- 2 Algorithme du pagerank
- 3 Implémentation
  - Les structures de données
  - Le programme
- 4 Bibliographie
- Conclusion

# Plan

- Introduction
- 2 Algorithme du pagerank
- 3 Implémentation
  - Les structures de données
  - Le programme
- 4 Bibliographie
- Conclusion

### Les vecteurs

### Vecteur mathématique

### Vecteur informatique

### Les matrices COO

# Matrice mathématique

$$\begin{pmatrix} 1 & 2 & 3 & 0 & 0 \\ 0 & 0 & 0 & 4 & 5 \\ 0 & 0 & 0 & 6 & 7 \\ 0 & 0 & 0 & 0 & 8 \\ 0 & 0 & 0 & 9 & 0 \end{pmatrix}$$

### Matrice informatique

```
\begin{cases} nnz &= 9 \\ rows &= [0;0;0;1;1;2;2;3;4] \\ cols &= [0;1;2;3;4;3;4;4;3] \\ values &= [1;2;3;4;5;6;7;8;9] \end{cases}
```

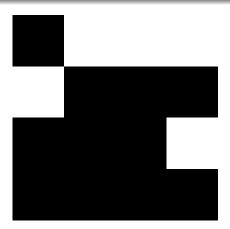


Figure: Matrice d'adjacence du graphe interstices\_1

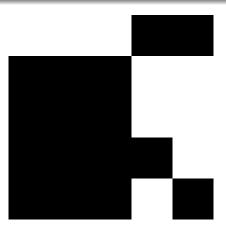


Figure: Matrice d'adjacence du graphe interstices\_2

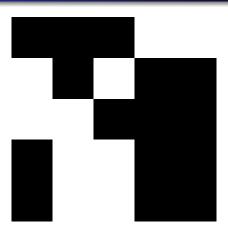


Figure: Matrice d'adjacence du graphe interstices\_3

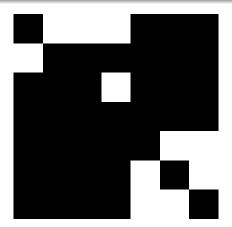


Figure: Matrice d'adjacence du graphe interstices\_4

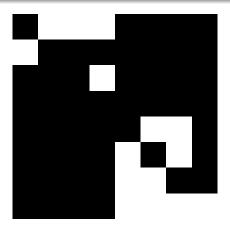


Figure: Matrice d'adjacence du graphe interstices\_5

# Plan

- Introduction
- Algorithme du pagerank
- 3 Implémentation
  - Les structures de données
  - Le programme
- 4 Bibliographie
- Conclusion

#### Processus maître

- lecture du graphe écrit dans un fichier
- création de la matrice transposée d'adjacence
- matrice rendue stochastique en colonnes
- calcul d'une répartition équitable entre les processus esclaves
- MPI\_Send

- MPI\_Recv
- multiplication par le damping factor

#### Processus maître

- lecture du graphe écrit dans un fichier
- création de la matrice transposée d'adjacence
- matrice rendue stochastique en colonnes
- calcul d'une répartition équitable entre les processus esclaves
- MPI\_Send

- MPI\_Recv
- multiplication par le damping factor

#### Processus maître

- lecture du graphe écrit dans un fichier
- création de la matrice transposée d'adjacence
- matrice rendue stochastique en colonnes
- calcul d'une répartition équitable entre les processus esclaves
- MPI\_Send

- MPI\_Recv
- multiplication par le damping factor

#### Processus maître

- lecture du graphe écrit dans un fichier
- création de la matrice transposée d'adjacence
- matrice rendue stochastique en colonnes
- calcul d'une répartition équitable entre les processus esclaves
- MPI\_Send

- MPI\_Recv
- multiplication par le damping factor

#### Processus maître

- lecture du graphe écrit dans un fichier
- création de la matrice transposée d'adjacence
- matrice rendue stochastique en colonnes
- calcul d'une répartition équitable entre les processus esclaves
- MPI\_Send

- MPI\_Recv
- multiplication par le damping factor

#### Processus maître

- lecture du graphe écrit dans un fichier
- création de la matrice transposée d'adjacence
- matrice rendue stochastique en colonnes
- calcul d'une répartition équitable entre les processus esclaves
- MPI\_Send

- MPI\_Recv
- multiplication par le damping factor

#### Processus maître

- MPT Allreduce
- ajout du terme complémentaire du damping factor à next\_pagerank
- calcul de la distance entre pagerank et next\_pagerank
- MPI\_Bcast
- prise de décision d'itérer une nouvelle fois le calcul ou non en fonction de la précision souhaitée

- multiplication de pagerank par la sous-matrice
- MPI\_Allreduce
- ajout du terme complémentaire du damping factor à next\_pagerank
- MPI Bcast
- prise de décision d'itérer une nouvelle fois le calcul ou non en fonction de la précision souhaitée
- copie de next\_pagerank dans pagerank

#### Processus maître

- MPI\_Allreduce
- ajout du terme complémentaire du damping factor à next\_pagerank
- calcul de la distance entre pagerank et next\_pagerank
- MPI\_Bcast
- prise de décision d'itérer une nouvelle fois le calcul ou non er fonction de la précision souhaitée

- multiplication de pagerank par la sous-matrice
- MPI Allreduce
- ajout du terme complémentaire du damping factor à next\_pagerank
- MPI Bcast
- prise de décision d'itérer une nouvelle fois le calcul ou non en fonction de la précision souhaitée
- copie de next\_pagerank dans pagerank

#### Processus maître

- MPI\_Allreduce
- ajout du terme complémentaire du damping factor à next\_pagerank
- calcul de la distance entre pagerank et next\_pagerank
- MPI\_Bcast
- prise de décision d'itérer une nouvelle fois le calcul ou non en fonction de la précision souhaitée

- multiplication de pagerank par la sous-matrice
- MPI\_Allreduce
- ajout du terme complémentaire du damping factor à next\_pagerank
- MPI\_Bcast
- prise de décision d'itérer une nouvelle fois le calcul ou non en fonction de la précision souhaitée
- copie de next\_pagerank dans pagerank

#### Processus maître

- MPT Allreduce
- ajout du terme complémentaire du damping factor à next\_pagerank
- calcul de la distance entre pagerank et next\_pagerank
- MPI\_Bcast
- prise de décision d'itérer une nouvelle fois le calcul ou non er fonction de la précision souhaitée

- multiplication de pagerank par la sous-matrice
- MPI\_Allreduce
- ajout du terme complémentaire du damping factor à next\_pagerank
- MPI\_Bcast
- prise de décision d'itérer une nouvelle fois le calcul ou non en fonction de la précision souhaitée
- copie de next\_pagerank dans pagerank

#### Processus maître

- MPI\_Allreduce
- ajout du terme complémentaire du damping factor à next\_pagerank
- calcul de la distance entre pagerank et next\_pagerank
- MPI\_Bcast
- prise de décision d'itérer une nouvelle fois le calcul ou non er fonction de la précision souhaitée

- multiplication de pagerank par la sous-matrice
- MPI\_Allreduce
- ajout du terme complémentaire du damping factor à next\_pagerank
- MPI Bcast
- prise de décision d'itérer une nouvelle fois le calcul ou non en fonction de la précision souhaitée
- copie de next\_pagerank dans pagerank

#### Processus maître

- MPI\_Allreduce
- ajout du terme complémentaire du damping factor à next\_pagerank
- calcul de la distance entre pagerank et next\_pagerank
- MPI\_Bcast
- prise de décision d'itérer une nouvelle fois le calcul ou non en fonction de la précision souhaitée

- multiplication de pagerank par la sous-matrice
- MPI Allreduce
- ajout du terme complémentaire du damping factor à next\_pagerank
- MPI Bcast
- prise de décision d'itérer une nouvelle fois le calcul ou non en fonction de la précision souhaitée
- copie de next\_pagerank dans pagerank

#### Processus maître

- MPI\_Allreduce
- ajout du terme complémentaire du damping factor à next\_pagerank
- calcul de la distance entre pagerank et next\_pagerank
- MPI Bcast
- prise de décision d'itérer une nouvelle fois le calcul ou non en fonction de la précision souhaitée

- multiplication de pagerank par la sous-matrice
- MPI Allreduce
- ajout du terme complémentaire du damping factor à next\_pagerank
- MPI Bcast
- prise de décision d'itérer une nouvelle fois le calcul ou non en fonction de la précision souhaitée
- copie de next\_pagerank dans pagerank

### **Finalisation**

#### Processus maître

 écriture des résultats dans un fichier

### Plan

- Introduction
- 2 Algorithme du pagerank
- Implémentation
  - Les structures de données
  - Le programme
- 4 Bibliographie
- Conclusion

# PageRank

- [1] The Anatomy of a Large-Scale Hypertextual Web Search Engine, Sergey Brin and Lawrence Page, 1998, infolab.stanford.edu/~backrub/google.html
- [2] Using your laptop to compute PageRank for millions of webpages, Michael Nielsen, 2008, michaelnielsen.org/blog/using-your-laptop-to-compute-pagerank-for-millions-of-webpages/
- [3] Le theorème de Perron-Frobenius, les chaines de Markov et un célèbre moteur de recherche, Bachir Bekka, 2007, agreg-maths.univ-rennes1.fr/documentation/docs/Perron-Frobenius.pdf
- [4] La formule de PageRank sur des exemples, interstices.info/encart.jsp?id=c\_21839&encart=0& size=780,580

### **Divers**

- [5] A description on how to use and modify libpng, Glenn Randers-Pehrson, 2016, www.libpng.org/pub/png/libpng-manual.txt
- [6] CUDA Toolkit Documentation, docs.nvidia.com/cuda/cusparse/

## Plan

- Introduction
- 2 Algorithme du pagerank
- 3 Implémentation
  - Les structures de données
  - Le programme
- 4 Bibliographie
- Conclusion

### Travail réalisé

- Cahier des charges rempli
- Code segmenté en librairies réutilisables

### Points d'amélioration

- Utilisation des matrices au format CSR
- Meilleure répartition des données entre les processus
- Analyse des temps d'exécution

### Remerciements

- À Frédéric MAGOULES pour ses cours et ses conseils ;
- À VIA Centrale Réseaux pour m'avoir fourni un cluster de test